



# Занятие 14. Временные ряды

Колмагоров Евгений  
[ml.hse.dpo@yandex.ru](mailto:ml.hse.dpo@yandex.ru)

27 января 2025

# План лекции

1. Виды временных рядов
2. Стационарность
3. Эконометрические модели
4. Адаптивные методы
5. Модели с трендом и сезонностью
6. Особенности обработки временных рядов



# Понятие временного ряда

Временной ряд – это последовательность значений описывающих протекающий во времени процесс, измеренных в последовательные моменты времени, обычно через равные промежутки.



# В каких задачах встречаются временные ряды

Задачи, связанные с обработкой и предсказаниями временных рядов широко встречаются в различных областях, но наиболее часто в экономических задачах:

- Предсказание стоимости ценных бумаг
- Курсов валют
- Цен различных активов: недвижимости, нефти, металлов и тд.
- Уровня ВВП
- Спроса на товары и услуги
- Прогнозирование погоды



# Задача прогнозирования временного ряда

$y_0, y_1, \dots, y_t, \dots$  – временной ряд,  $y_i \in \mathbb{R}$

**Задача:** Построить функцию

$$\hat{y}_{t+d}(w) = a_{t,d}(y_1, \dots, y_t; w)$$

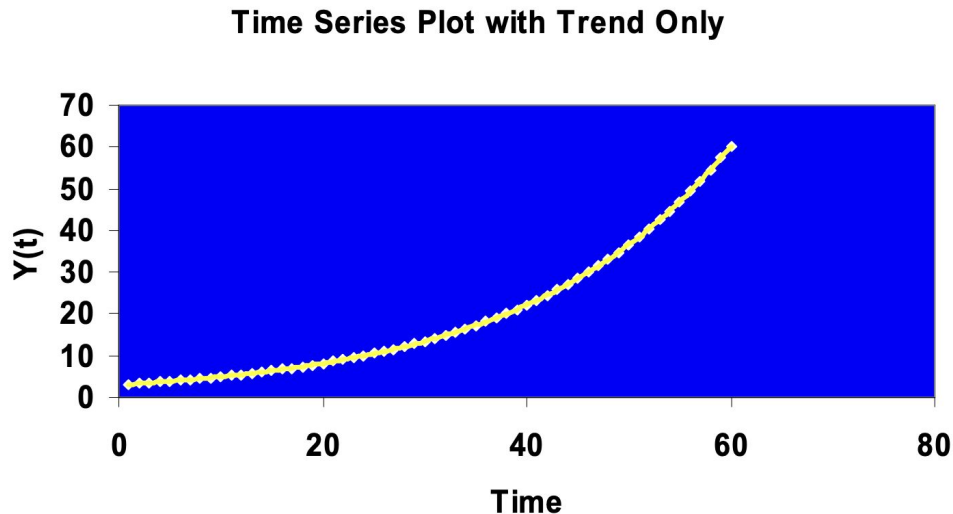
- $d = 1, \dots, D$ , где  $D$  – горизонт прогнозирования
- $w$  – вектор параметров модели

# Особенности временных рядов

- в стандартных задачах машинного обучения предполагается, что наблюдения независимы и одинаково распределены
- в задаче анализа временных рядов предполагаем, что ряд в прошлом содержит информацию о поведении ряда в будущем

# Компоненты временного ряда. Тренд


Тренд – плавное долгосрочное увеличение уровня ряда.



В данном случае ряд имеет тренд, так как значение  $Y$  монотонно возрастает

# Компоненты временного ряда. Сезонность

Сезонность – циклическое изменение уровня ряда с постоянным периодом



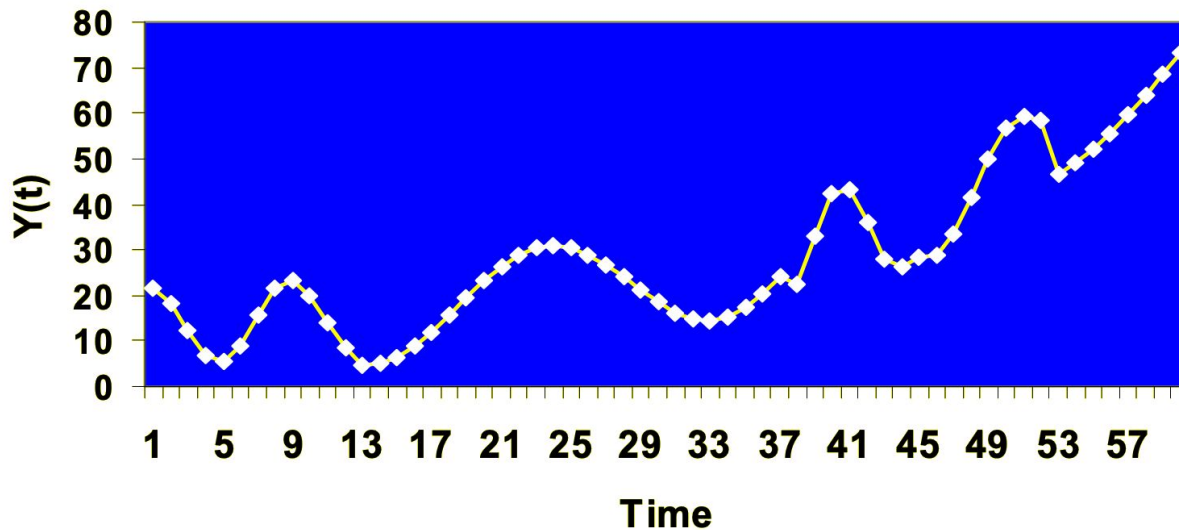
Ряд имеет как тренд так и сезонную компоненту



# Компоненты временного ряда. Цикличность


Циклы – изменение уровня ряда с переменным периодом

**Cylic Activity with Trend**



# Компоненты временного ряда. Шум

Шум (ошибка) – непрогнозируемая случайная компонента ряда



# Стационарность в узком смысле

Ряд  $y_1, \dots, y_T$  стационарен в узком смысле, если для любого  $s$  распределение  $y_1, \dots, y_m$  совпадает с распределением  $y_s, \dots, y_{m+s}$ . То есть свойства ряда не зависят от времени.

$$F(y_1, \dots, y_m) = F(y_s, \dots, y_{m+s})$$

# Стационарность в широком смысле

Ряд  $Y_t$  называется стационарным в широком смысле, если

- $E(Y_t) = \mu$  при всех  $t$
- $\text{Var}(Y_t) = \sigma$  при всех  $t$
- $\text{cov}(Y_t, Y_{t+s}) = f(s)$  – зависит только от  $s$ , но не от  $t$

# Почему важна стационарность

- По стационарному ряду просто построить прогноз, так как мы полагаем, что его будущие статистические характеристики не будут отличаться от наблюдаемых текущих
- Если ряд имеет тренд или сезонность, то тогда ряд не стационарен, поэтому при прогнозировании стараются избавиться от этих двух компонент

# Пример. Проверка стационарности

Попробуем доказать, что ряд ниже стационарен


$$Y_t = \beta_1 Y_{t-1} + \varepsilon, \text{ где } -1 < \beta < 1 \text{ и } \varepsilon \sim N(0, \sigma)$$

$$Y_t = \beta_1(\beta_1 Y_{t-1} + \varepsilon) + \varepsilon = \dots = \beta_1^t Y_0 + \beta_1^{t-1} \varepsilon_1 + \dots + \beta_1 \varepsilon_{t-1} + \varepsilon_t$$

$$\mathbb{E}(Y_t) = \beta_1^t Y_0 + \beta_1^{t-1} \mathbb{E}\varepsilon_1 + \dots + \beta_1 \mathbb{E}\varepsilon_{t-1} + \mathbb{E}\varepsilon_t = \beta_1^t Y_0 \rightarrow 0$$

$$\begin{aligned} \sigma^2(Y_t) &= \mathbb{D}[\beta_1^t Y_0 + \beta_1^{t-1} \varepsilon_1 + \dots + \beta_1 \varepsilon_{t-1} + \varepsilon_t] = \\ &= \beta_1^{2t-2} \sigma_\varepsilon^2 + \dots + \beta_1^2 \sigma_\varepsilon^2 + \sigma_\varepsilon^2 = \frac{1-\beta^{2t}}{1-\beta^2} \sigma_\varepsilon^2 \rightarrow \frac{1}{1-\beta^2} \sigma_\varepsilon^2 \end{aligned}$$

# Пример стационарного ряда



# Единичный корень


**Определение:** Если ряд  $Y_t = \beta_1 Y_{t-1} + \varepsilon$  имеет коэффициент  $\beta$  равный 1, то говорят, что ряд имеет единичный корень

Модель случайного блуждания, канонический пример ряда с единичным корнем:

$$Y_t = Y_{t-1} + \varepsilon_t$$




# Пример нестационарного ряда. Случайное блуждание



Видно, что при  $\beta_1=1$  процесс не возвращается к своему среднему, а значит, не является стационарным

# Пример нестационарного ряда. Случайное блуждание



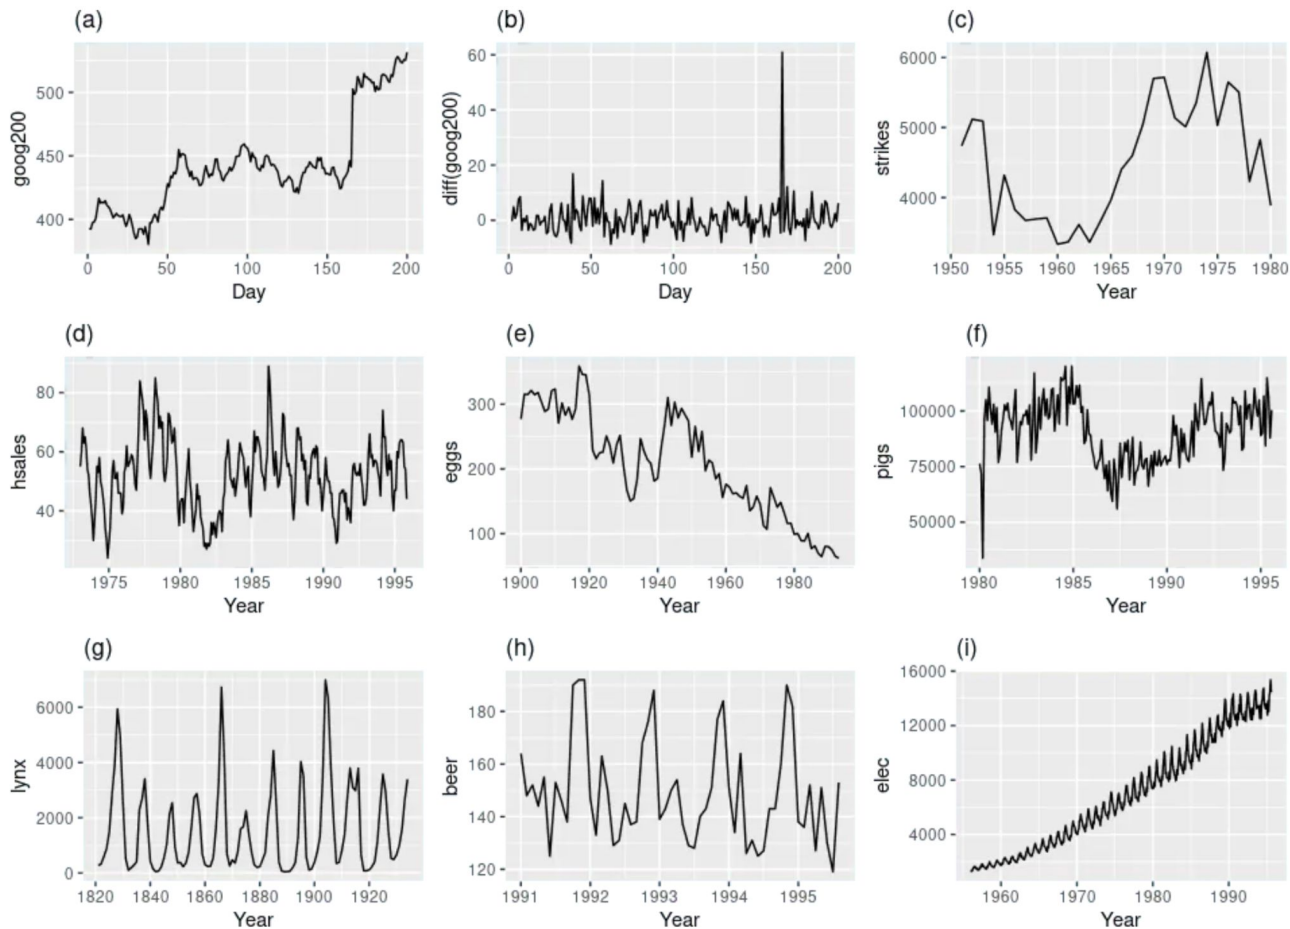
# Проверка стационарности

Как можно было заметить формальное доказательство стационарности ряда представляет собой не самую простую задачу с точки зрения математики.

Для того, чтобы проводить быстрые тесты на стационарность используют методы основанные на проверки гипотез:

- Критерий Дики-Фуллера
- Критерий KPSS (Kwiatkowski–Phillips–Schmidt–Shin)

# Попробуйте найти стационарный ряд

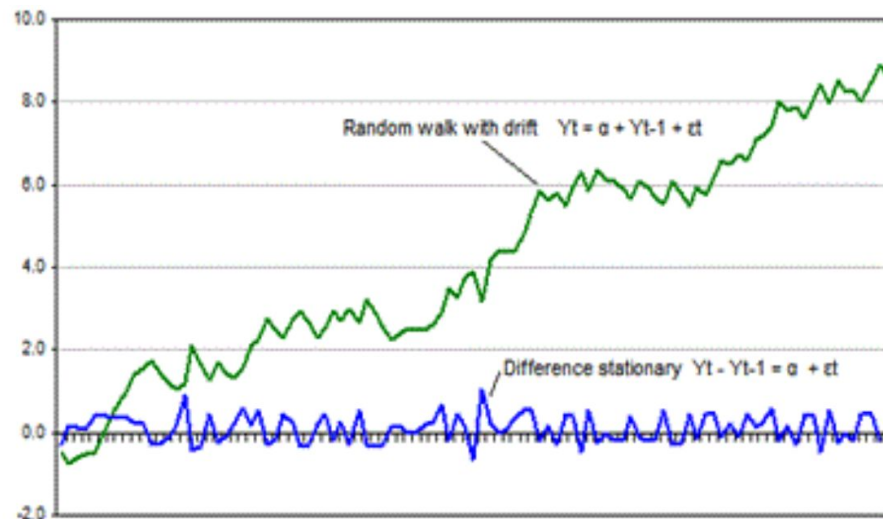


# Методы избавления от нестационарности

**Дифференцирование** – переход к попарным разностям для соседних значений ряда

$$y'_t = y_t - y_{t-1}$$

- Стабилизирует среднее значение ряда, позволяет избавиться от тренда
- Можно применять неоднократно



# Методы избавления от нестационарности


Для рядов с монотонно изменяющейся дисперсией (гетероскедастичные ряды) можно использовать стабилизирующее преобразование Бокса-Кокса:

$$y'_t = \begin{cases} \ln y_t, & \lambda = 0 \\ \frac{y_t^\lambda - 1}{\lambda}, & \text{где } \lambda \neq 0 \end{cases}$$


- Параметр  $\lambda$  подбирается так, чтобы сделать дисперсию как можно более однородной

# Стабилизация дисперсии


Исходный ряд



Параметр  $\lambda=0$



Параметр  $\lambda=0.3$



# Поиск сезонности и тренда

При наличии во временном ряде тренда и сезонных колебаний значения любого последующего элемента ряда зависит от предыдущих.

Определение: Корреляция (зависимость) между последовательными элементами временного ряда – это автокорреляция

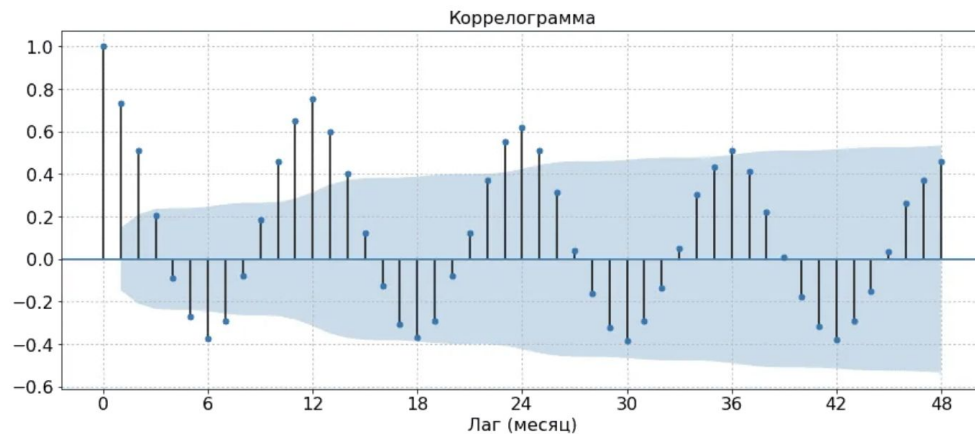

$$r_{\tau} = r_{y_t y_{t+\tau}} = \frac{\sum_{t=1}^{T-\tau} (y_t - \bar{y})(y_{t+\tau} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2}, \quad \bar{y} = \frac{1}{T} \sum_{t=1}^T y_t$$



# Автокорреляция


**Коррелограмма** – график, визуализирующий автокорреляционную функцию

**Автокорреляционная функция** – множество коэффициентов корреляции для различных смещений




# Коррелограмма стационарного процесса

Автокорреляционная  
функция  
стационарного  
процесса быстро  
убывает с ростом  $\tau$



# Коррелограмма нестационарного процесса

## Коррелограмма



# Частная автокорреляция

**Частная автокорреляционная функция** – “чистая корреляция” между  $X_t$  и  $X_{t-k}$  при исключении влияния  $X_{t-1}, X_{t-2}, \dots, X_{t-k+1}$

Вычисляется как оценка коэффициента  $\beta_k$  методом наименьших квадратов для в регрессии

$$Y_t = \beta_0 + \beta_1 X_{t-1} + \beta_2 X_{t-2} + \dots + \beta_k X_{t-k} + \varepsilon_t$$

# Эконометрические модели временных рядов


Модель авторегрессии AR(p):

$$y_t = \alpha + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + \varepsilon_t$$


- $\alpha_p \neq 0$
- $\varepsilon$  - процесс белого шума,  $\varepsilon \sim N(0, \sigma^2)$
- $\text{cov}(\varepsilon_t, \varepsilon_s) = 0$

# Модель авторегрессии

AR(1)



AR(2)




# Модель скользящего среднего

Модель скользящего среднего порядка  $q$  (MA( $q$ )):

$$y_t = \beta + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \beta_2 \varepsilon_{t-2} + \dots + \beta_q \varepsilon_{t-q}$$

- $\beta_q \neq 0$
- $\varepsilon_t$  - процесс белого шума,  $\varepsilon_t \sim N(0, \sigma^2)$
- $\text{cov}(\varepsilon_t, \varepsilon_s) = 0$
- Модель скользящего среднего всегда стационарна

# Модель скользящего среднего



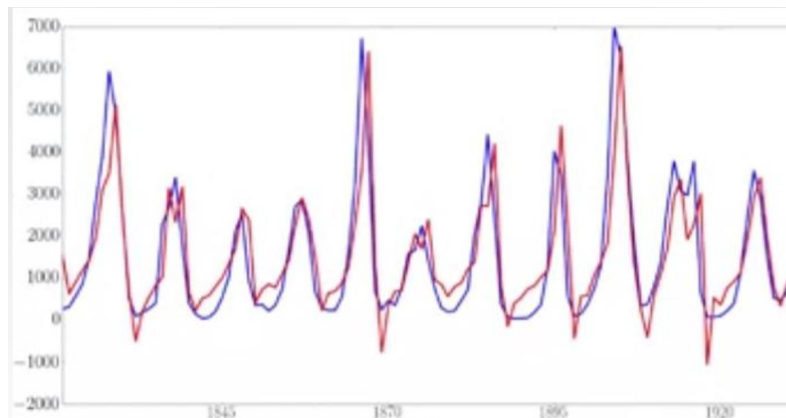


# Смешанный процесс авторегрессии

Смешанный процесс авторегрессии ARMA(p, q):


$$y_t = \alpha + \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q}$$

**Теорема Вольда:** Любой стационарный ряд можно приблизить моделью ARMA(p, q) сколь угодно точно.



# Модель ARIMA

- Модель  $ARIMA(p, q, d)$  – модель  $ARMA(p, q)$  для  $d$  раз продифференцированного ряда.




# Адаптивные методы. Скользящее среднее

$$\hat{y}_{t+1} = \frac{1}{k} \sum_{i=0}^{k-1} y_{t-i}$$

- Чтобы сделать прогноз на следующий период времени, надо знать значение на текущий (т.е. долгосрочный прогноз невозможен)
- Сглаживает данные и уменьшает влияние выбросов

# Влияние размера окна на прогнозы



# Экспоненциальное скользящее среднее

**Идея метода:** На значение ряда в данный момент времени больше влияет значение в предыдущий момент времени, затем – значение в предпредыдущий момент и т.д. (то есть более поздние данные – более важные).

$$\hat{y}_t = \alpha y_{t-1} + (1 - \alpha) \hat{y}_{t-1}$$

Пример:

$$Y_t = \frac{1}{2} y_{t-1} + \frac{1}{4} y_{t-2} + \frac{1}{8} y_{t-3} + \dots$$

# Обоснование метода

- Будем делать прогноз в момент времени  $t+1$  простейшей прогнозной моделью – константой ( $c = c_t$ ):  $\hat{y}_{t+1} = c$
- Минимизируем среднеквадратичную ошибку с весами  $\beta^i$ , убывающим в прошлое:

$$\sum_{t=0}^T \beta^{T-t} (y_t - c)^2 \rightarrow \min_c$$

- Приравниваем производную к 0:

$$2 \sum_{t=0}^T \beta^{T-t} (y_t - c) = 0$$

# Обоснование метода

- Выразим  $c$  и воспользуемся формулой разложения  $1/(1-x)$  в ряд Тейлора:

$$\begin{aligned} c &= \frac{\sum_{t=0}^T \beta^{T-t} y_t}{\sum_{t=0}^T b^t} \approx \frac{\sum_{t=0}^T \beta^{T-t} y_t}{1/(1-\beta)} = (1-\beta) \sum_{t=0}^T \beta^{T-t} y_t = \\ &= (1-\beta) y_T + (1-\beta) \beta \sum_{t=0}^{T-1} \beta^{T-t-1} y_t = (1-\beta) y_t + \beta \hat{y}_t \end{aligned}$$

- Получили модель экспоненциального сглаживания с  $\alpha = (1 - \beta)$

# Свойства


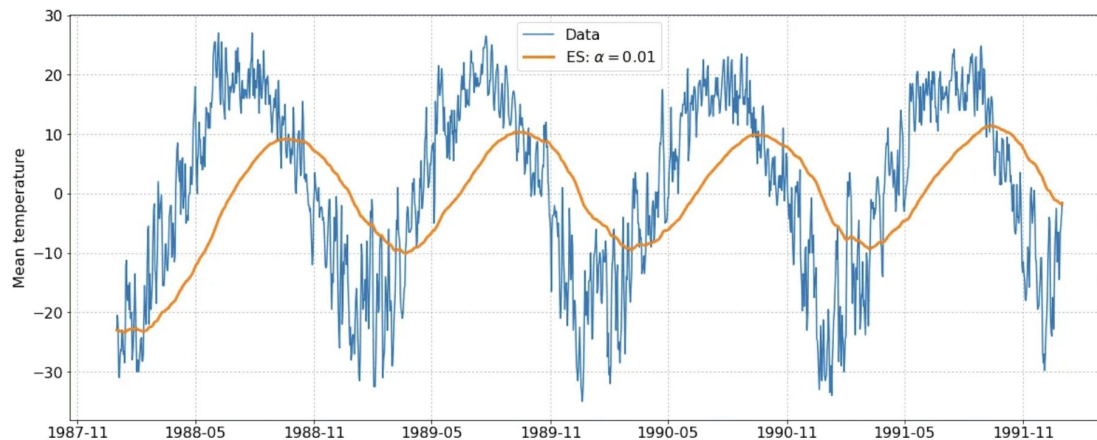
$$\hat{y}_t = \alpha y_{t-1} + (1 - \alpha) \hat{y}_{t-1}$$

- Чем больше  $\alpha$  тем больше вес последним значениям ряда, поэтому получается слабое сглаживание
- При малых  $\alpha$  больший вес отдаётся сглаженному значению и сглаживание становится сильнее
- Оптимальное значение  $\alpha$  можно получить по графику либо оптимизируя:


$$\sum_{t=0}^T (\hat{y}_t(\alpha) - y_t)^2 \rightarrow \min_{\alpha}$$



# Влияние параметра на прогнозы



# Модели с трендом и сезонностью



- Ряд 1 – сезонность без тренда
- Ряд 2 – линейный тренд аддитивная сезонность
- Ряд 3 – линейный тренд мультипликативная сезонность
- Ряд 4 – линейный тренд экспоненциальная сезонность

# Модели с трендом и сезонностью

- **Модель Хольта** – модель линейного тренда:

$$\hat{y}_{t+d} = a_t + b_t d$$

- $a_t, b_t$  – адаптивные компоненты линейного тренда, рассчитываемые как

$$a_t = \alpha_1 y_t + (1 - \alpha_1)(a_{t-1} + b_{t-1})$$

$$b_t = \alpha_2 (a_t - a_{t-1}) + (1 - \alpha_2)b_{t-1}$$

- где  $\alpha_1, \alpha_2$  – параметры сглаживания

# Модели с трендом и сезонностью

- **Модель Тейла-Вейджа** – модель линейного тренда с аддитивной сезонностью:

$$\hat{y}_{t+d} = (a_t + b_t d) + \theta_{t+(d \bmod s)-s}$$

- $a_t + b_t d$  – тренд, очищенный от сезонных колебаний  $\theta_0, \dots, \theta_{s-1}$  – сезонный профиль периода без тренда

$$a_t = \alpha_1 y_t + (1 - \alpha_1)(a_{t-1} + b_{t-1})$$

$$b_t = \alpha_2 (a_t - a_{t-1}) + (1 - \alpha_2) b_{t-1}$$

$$\theta_t = \alpha_3 (y_t - a_t) + (1 - \alpha_3) \theta_{t-s}$$

# Адаптивная модель авторегрессии

Линейная модель авторегрессии (линейный фильтр):

$$\hat{y}_{t+1} = \sum_{j=0}^d w_j y_{t-j+1}$$

- Обучающее множество

$$F_{\ell \times n} = \begin{pmatrix} y_{t-1} & y_{t-2} & y_{t-3} & \dots & y_{t-n} \\ y_{t-2} & y_{t-3} & y_{t-4} & \dots & y_{t-n-1} \\ \dots & \dots & \dots & \dots & \dots \\ y_n & y_{n-1} & y_{n-2} & \dots & y_1 \\ y_{n-1} & y_{n-2} & y_{n-3} & \dots & y_0 \end{pmatrix}, \quad y_{\ell \times 1} = \begin{pmatrix} y_t \\ y_{t-1} \\ \dots \\ y_{n+1} \\ y_n \end{pmatrix}$$

- Функционал качества

$$Q(w) = \sum_{i=n}^t (\hat{y}_i(t) - y_i)^2 = \|Fw - y\|^2 \rightarrow \min_w$$

# Адаптивная модель авторегрессии

- Ошибка на прогнозе для момента времени  $t$ :

$$\varepsilon_t = y_t - \hat{y}_t$$

- Один шаг градиентного спуска в момент времени  $t$ :


$$w_j = w_j + h_t \varepsilon_t y_{t-j+1}$$

- Градиентный шаг:

$$h_t = \frac{\alpha}{\sum_{j=1}^n y_{t-j+1}^2}$$

# Адаптивная селекция и композиция моделей

Пример:  $|\epsilon_t|$  для нескольких моделей временного ряда



# Адаптивная селекция

- Пусть имеется  $k$  моделей прогнозирования,  $\hat{y}_{j,t+d}$  – прогноз  $j$ -ой модели на момент  $t+d$
- $\varepsilon_{jt} = y_t - \hat{y}_{jt}$  – ошибка прогноза в момент времени  $t$
- $\tilde{\varepsilon}_{jt} = \gamma|\varepsilon_{jt}| + (1 - \gamma)\tilde{\varepsilon}_{jt}$  – сглаженная ошибка
- Лучшая модель в момент времени  $t$ :

$$j_t^* = \underset{j=1,\dots,k}{\operatorname{argmin}} \tilde{\varepsilon}_{jt}$$

- Итоговый прогноз

$$\hat{y}_{t+d} = \hat{y}_{j_t^*, t+d}$$



# Адаптивная комбинация

- В каждый момент времени итоговое предсказание – это сумма предсказаний с весами, обратно пропорциональными их ошибкам
- Предсказание:

$$\hat{y}_{t+d} = \sum_{j=1}^k w_{jt} \hat{y}_{j.t+d}$$

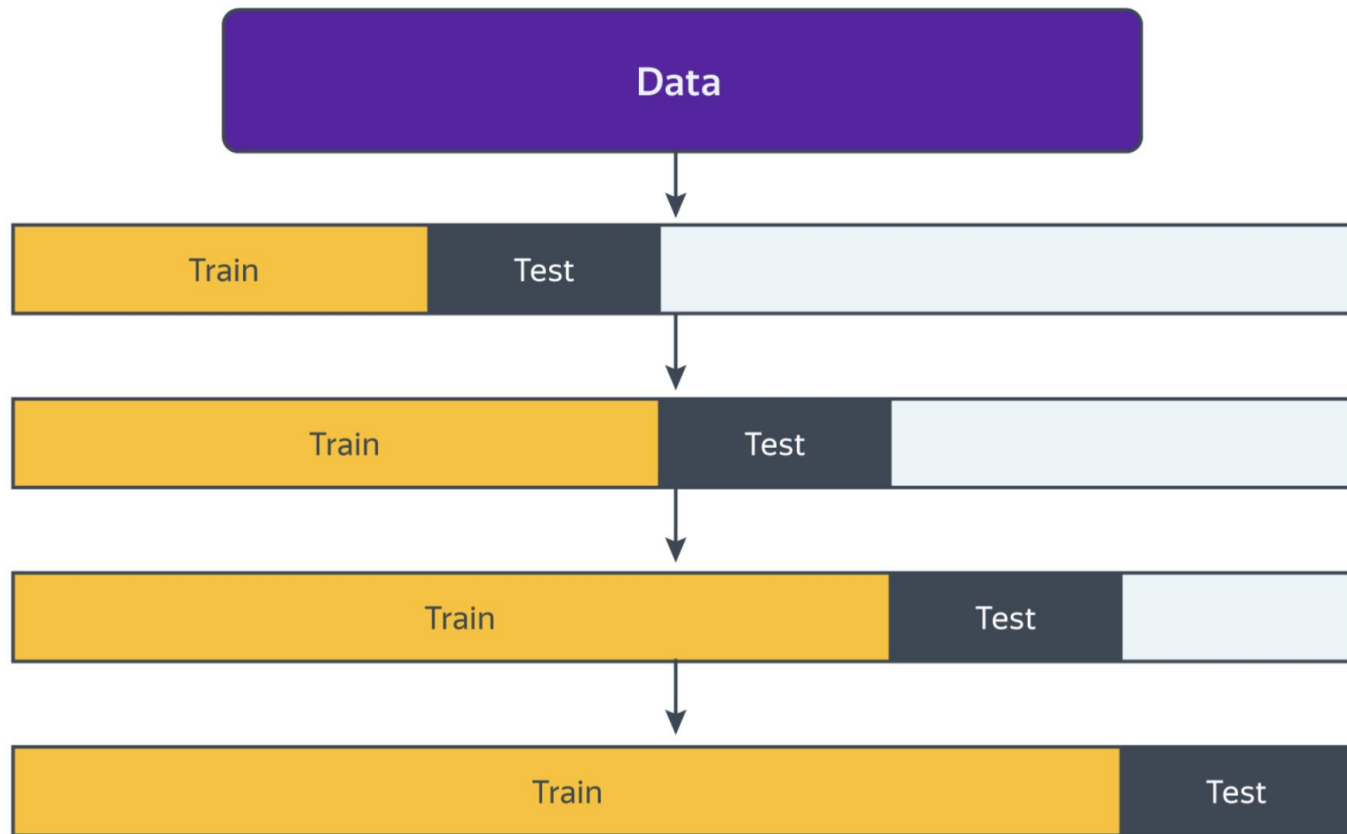
- Вес для отдельной модели:

$$w_{jt} = \frac{(\tilde{\varepsilon}_{jt})^{-1}}{\sum_{s=1}^k (\tilde{\varepsilon}_{jt})^{-1}}$$

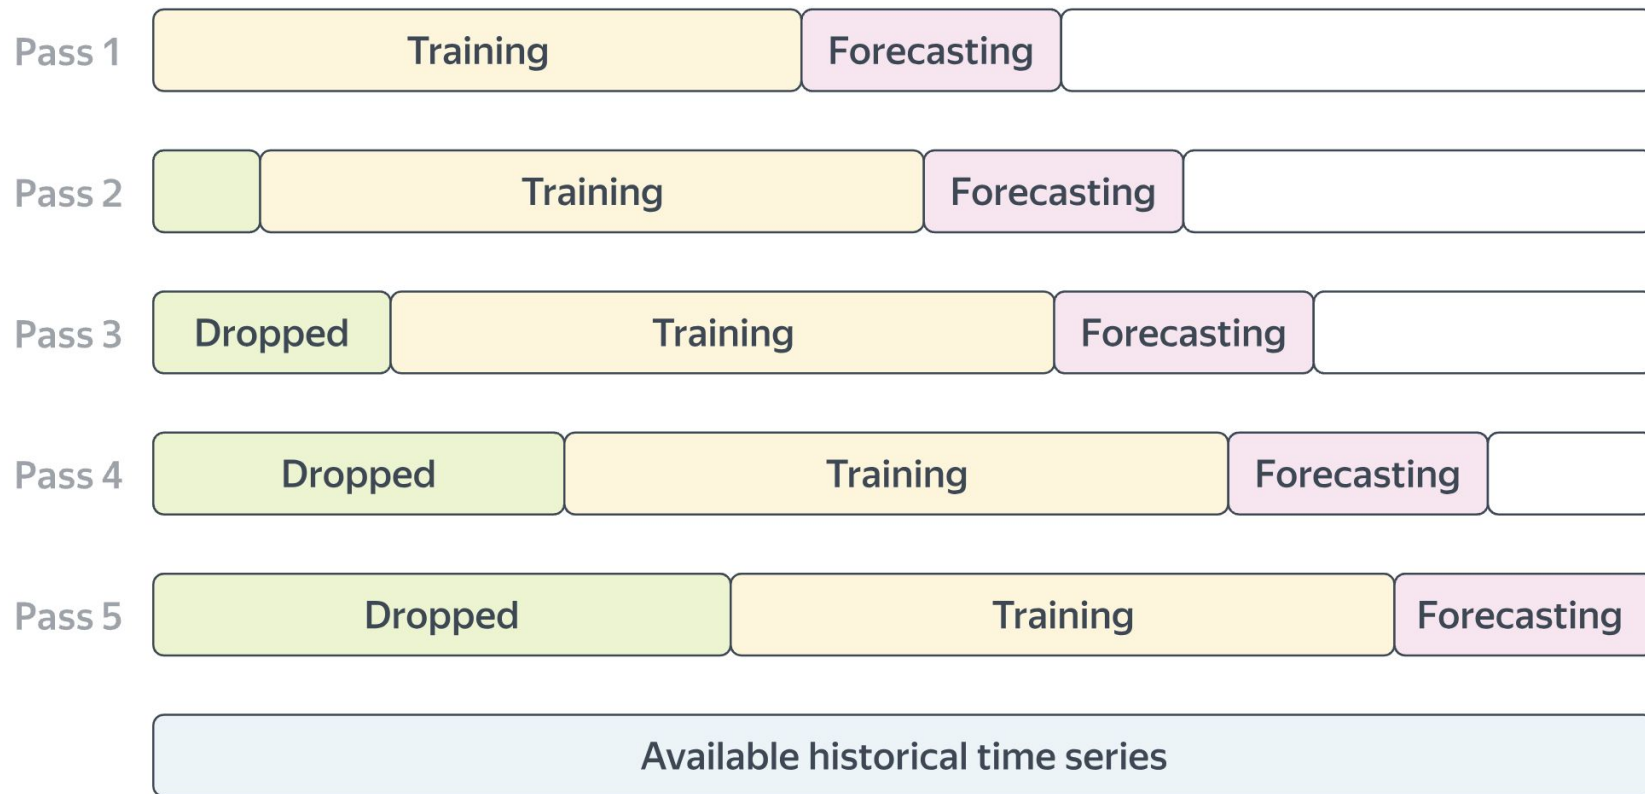
# Требования к задаче прогнозирования рядов

- Визуализация данных, анализ распределения признаков
- Подготовка данных: избавление от выбросов, подготовка признаков
- Настройка эконометрических моделей (ARMA, ARIMA и тд.)
- Настройка адаптивных моделей – автоматический подбор модели, проверка соответствия модели особенностям ряда
- Настройка регрессионных моделей машинного обучения
- Визуальный анализ
- Сравнение и выбор наилучшей модели
- Выводы

# Кросс-валидация для временных рядов



# Кросс-валидация для временных рядов



# Модели машинного обучения


- Часто затраты на настройку моделей (ARMA, ARIMA и тд.) не окупаются, поэтому имеет смысл попробовать применить методы машинного обучения к предсказанию временных рядов
- Можно использовать линейную регрессию, в качестве признаков для которой использовать лаговые признаки (значения признака предыдущие периоды времени).

# Машинное обучение: признаки

1. Лаги – значения временного ряда 1, 2, ... периодов назад
2. Агрегированные признаки по дате: среднее значение таргета для каждого дня недели месяца, года и тд.
3. Другие характеристик

# Facebook Prophet

- Facebook prophet от компании Facebook для задач предсказания временных рядов



# Что ещё почитать по временным рядам

- Пост на хабре по основам анализа и обработки временных рядов  
<https://habr.com/ru/companies/ods/articles/327242/>
- Лекция К.В. Воронцова  
<http://www.machinelearning.ru/wiki/images/archive/c/cb/20160412121749!voron-ml-forecasting-slides.pdf>
- Учебник от Яндекса, главы по работе с временными рядами:  
<https://education.yandex.ru/handbook/ml/article/vremennyye-ryady>